به نام خدا

عنوان درس:

داده کاوی پیشرفته

استاد درس:

خانم دکتر نوربخش

عنوان گزارشکار:

تحلیل داده های مجموعه داده استاندارد

مجموعه داده استاندارد:

تخمین کیفیت شراب با استفاده از پارامتر های شیمیایی

دانشجو:

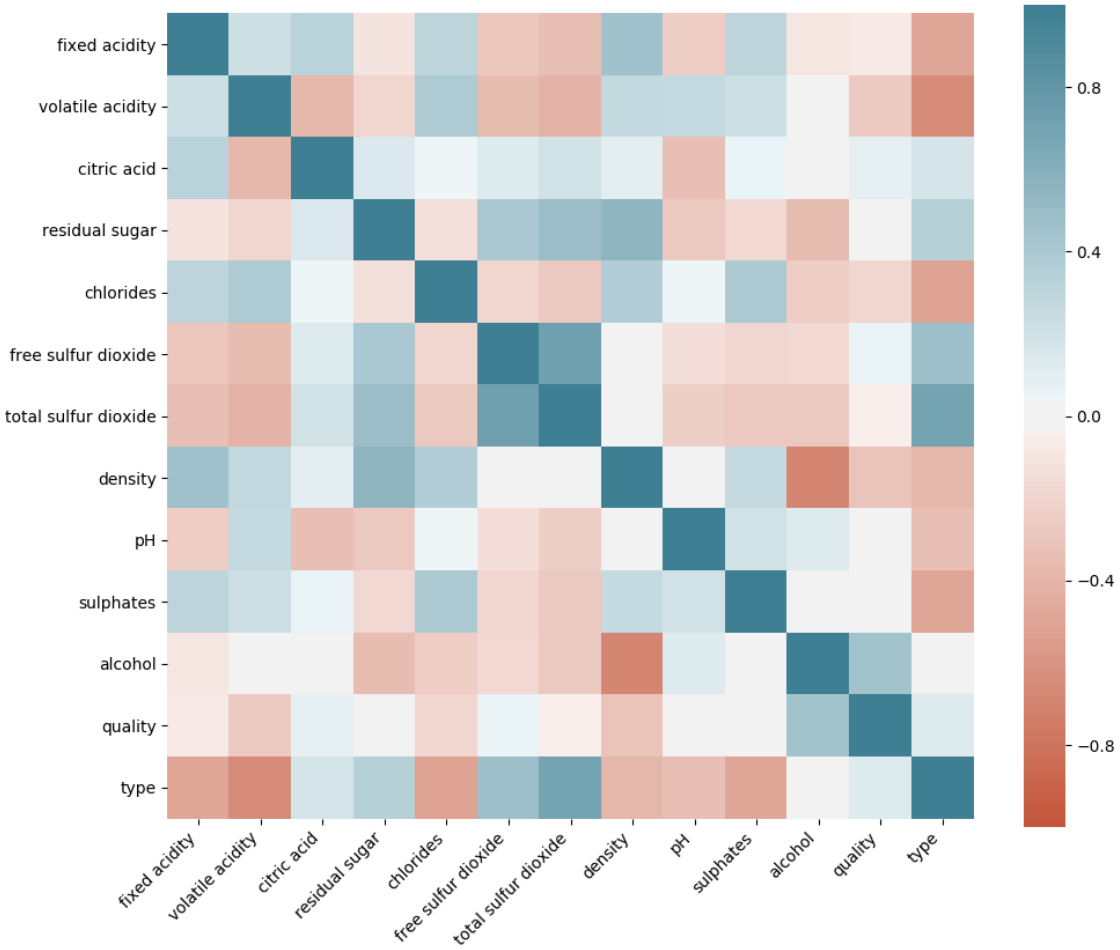
علی سپهرنیا

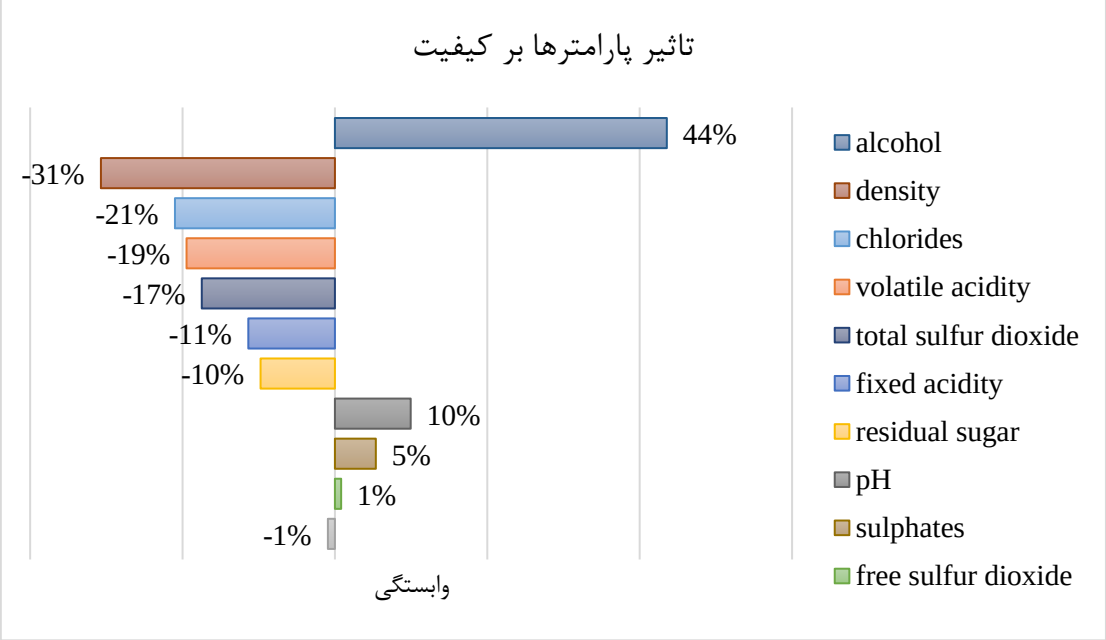
۱. مجموعه داده

مجموعه داده هدفی که توسط گروه انتخاب شد، Wine Quality است. قرار است به کمک برخی پارامترهای شیمیایی، کیفیت یک شراب تخمین زده شود. این مجموعه داده از دو سری داده متفاوت که مربوط به شراب قرمز و شراب سفید است، تشکیل شده است. با توجه به چالشی بودن مجموعه داده و با هدف تقریب دقیقتر در این تمرین تنها از سری داده های شراب سفید استفاده شده است. این مجموعه، شامل ۴۸۹۸ نمونه و ۱۲ صفت است به شرح زیر است:

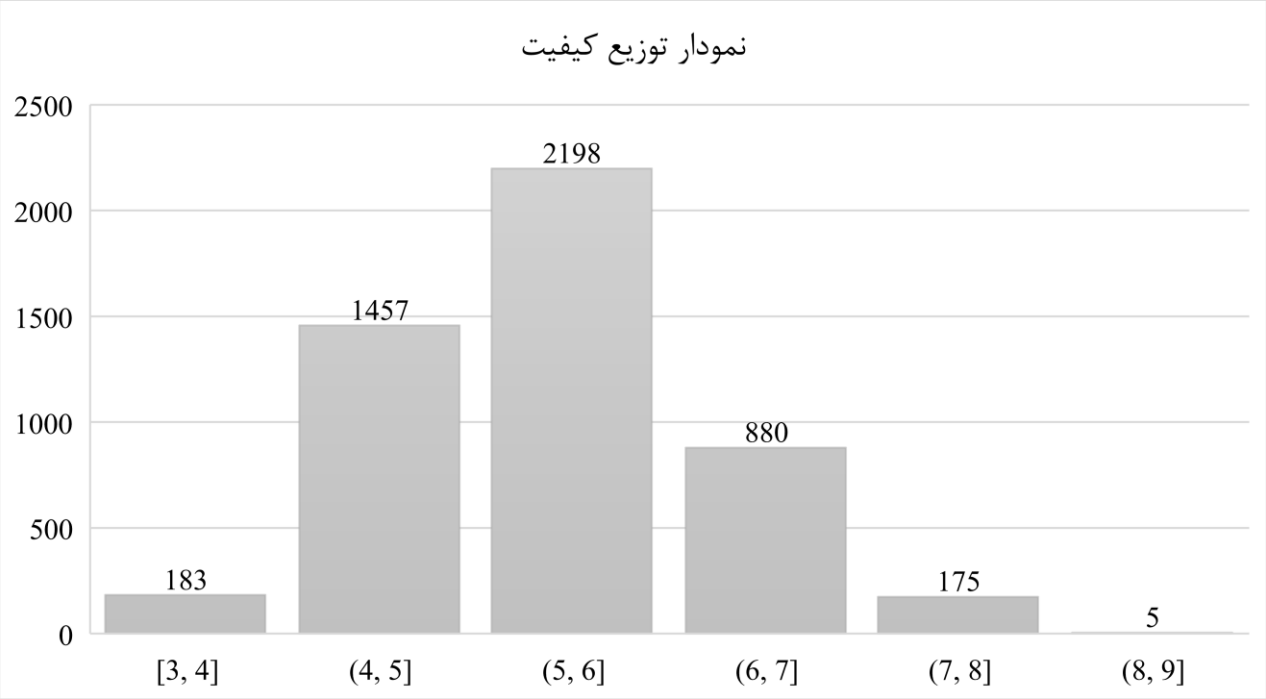
ردیف	نوع صفت	عنوان لاتین	شرح (مفهوم صفت)
۱	عدد اعشاری	Fixed Acidity	مجموع مقادیر اغلب اسیدهای موجود در شراب (این اسیدها در شراب ماندگارند و به راحتی تبخیر نمی شوند)
۲	عدد اعشاری	Volatile Acidity	مقدار اسیدهای فرار(استیک اسید) موجود در شراب (در مقادیر بالا باعث طعم ناخوشایند و سرکه ای شراب می شود.)
۳	عدد اعشاری	Citric Acid	مقدار اسید سیتریک (مقادیر کم آن به شراب، طراوت و طعم اضافه می کند)
۴	عدد اعشاری	Residual Sugar	مقدار قند باقی مانده در شراب پس از تخمیر (مقادیر بالای ۴۵ معرف شراب شیرین است)
۵	عدد اعشاری	Chlorides	مقدار نمک موجود در شراب
۶	عدد اعشاری	Free Sulfur Dioxide	مقدار SO2 آزاد (از رشد میکروب ها و اکسیداسیون شراب جلوگیری می کند)
۷	عدد اعشاری	Total Sulfur Dioxide	مجموع مقادیر SO2 آزاد و محلول
۸	عدد اعشاری	Density	چگالی (چگالی شراب بسته به مقدار الکل و قند به چگالی آب نزدیک است)
۹	عدد اعشاری	pH	مقیاس اسیدی/بازی بودن شراب (اکثر شرابها pH بین ۳ تا ۴ دارند)
۱۰	عدد اعشاری	Sulphates	مجموع مقادیر سولفات ها (یک افزودنی است که به سطح SO2 شراب به عنوان ضد میکروب و آنتی اکسیدان کمک میکند)
۱۱	عدد اعشاری	Alcohol	درصد الکل موجود در شراب
۱۲	عدد صحیح	Quality	کیفیت شراب (صفت هدف) (در مقیاس ۰(بدترین) تا ۱۰(بهترین) تعریف میشود.)

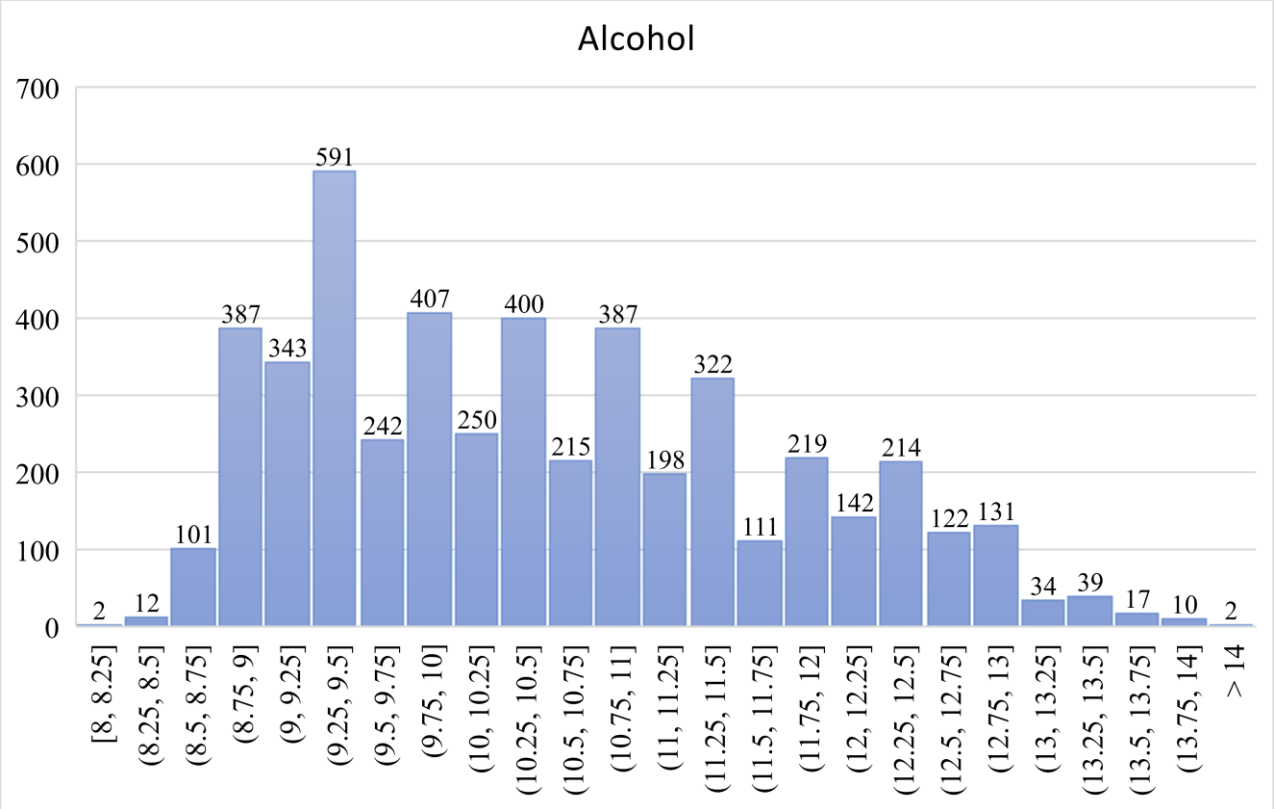
- **جدول و نمودار همبستگی:** نمودار اول میزان وابستگی پارامترهای مختلف بر هم را نشان می دهد و نمودار دوم میزان وابستگی هر صفت بر صفت هدف(کیفیت).

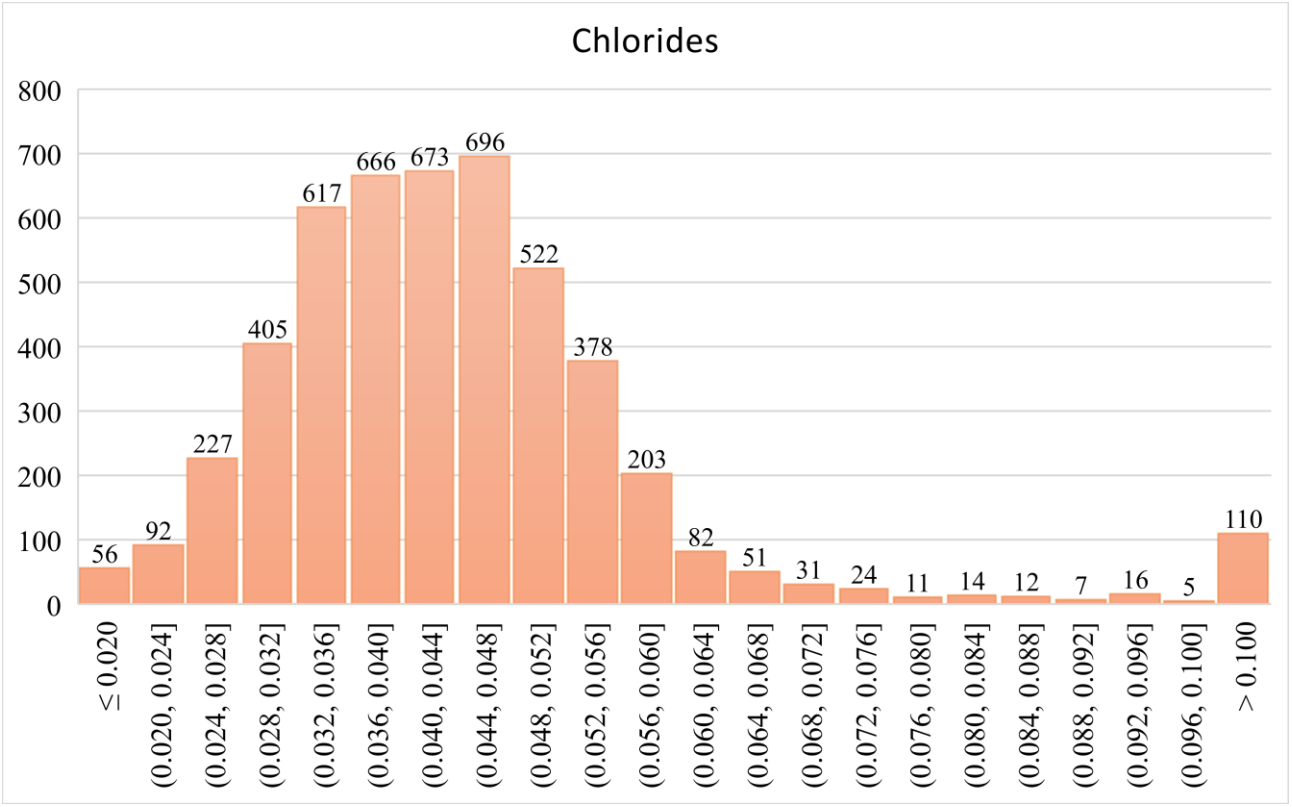


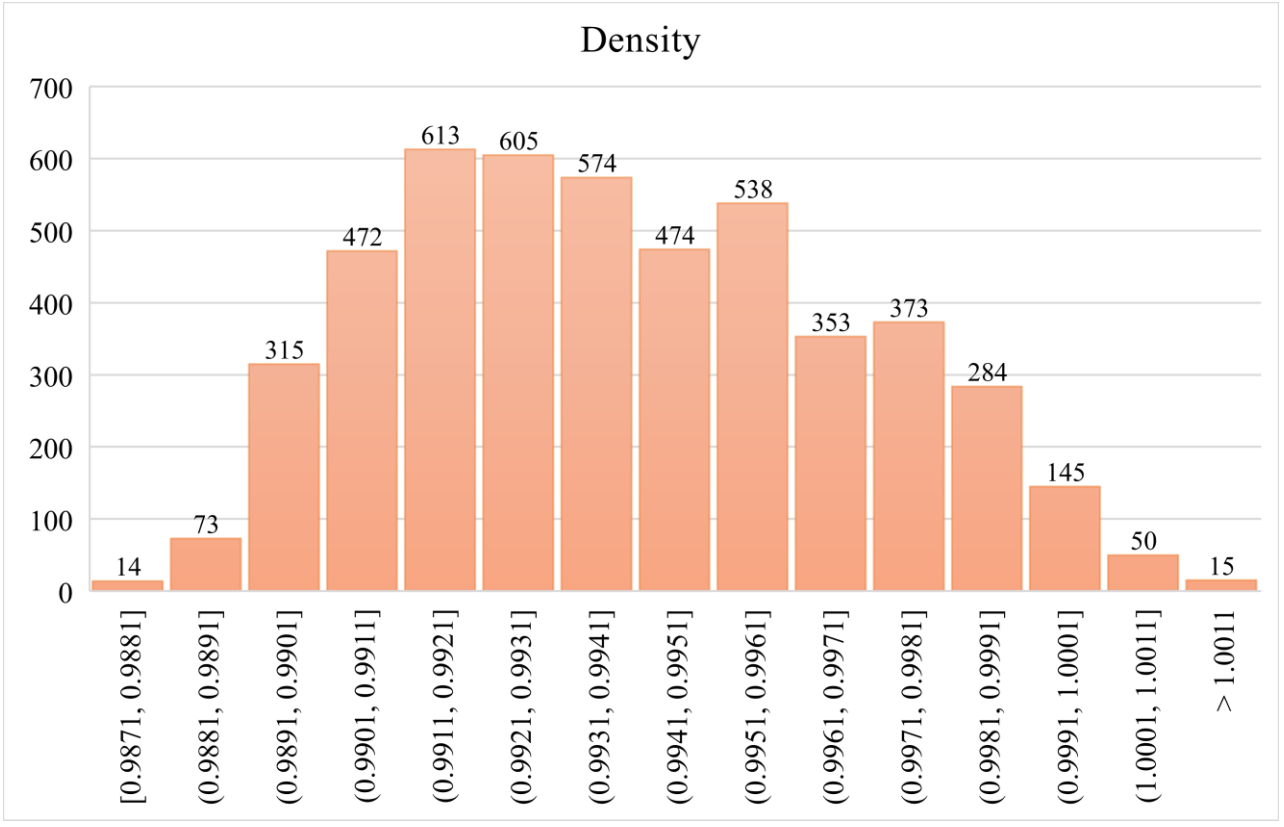


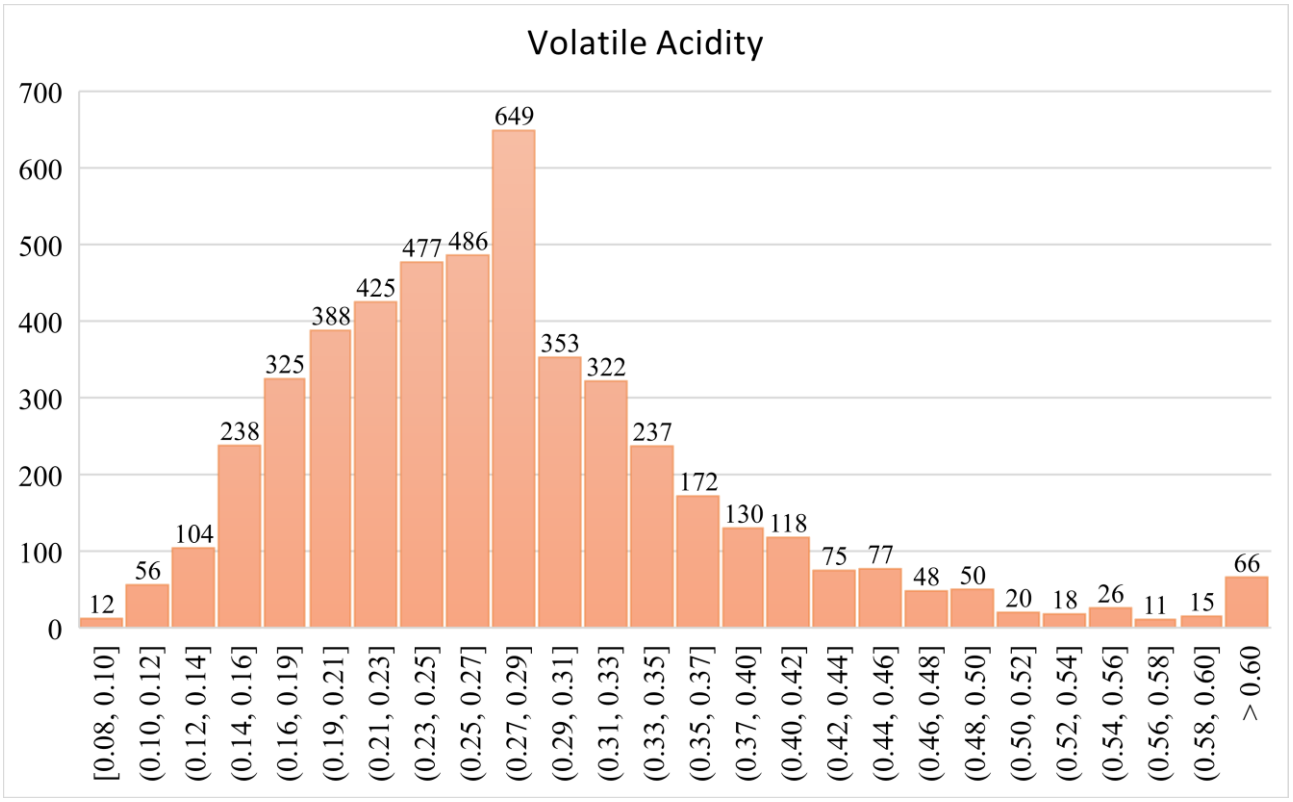
- **نمودارهای توزیع:** نمودارهای زیر پراکندگی نمونه های ما را در مقادیر مختلف مربوط به هر صفت نشان میدهد. نمودارهای آبی نشان دهنده نسبت مستقیم و نمودارهای نارنجی نشان دهنده نسبت معکوسِ بین آن صفت و کیفیت است.

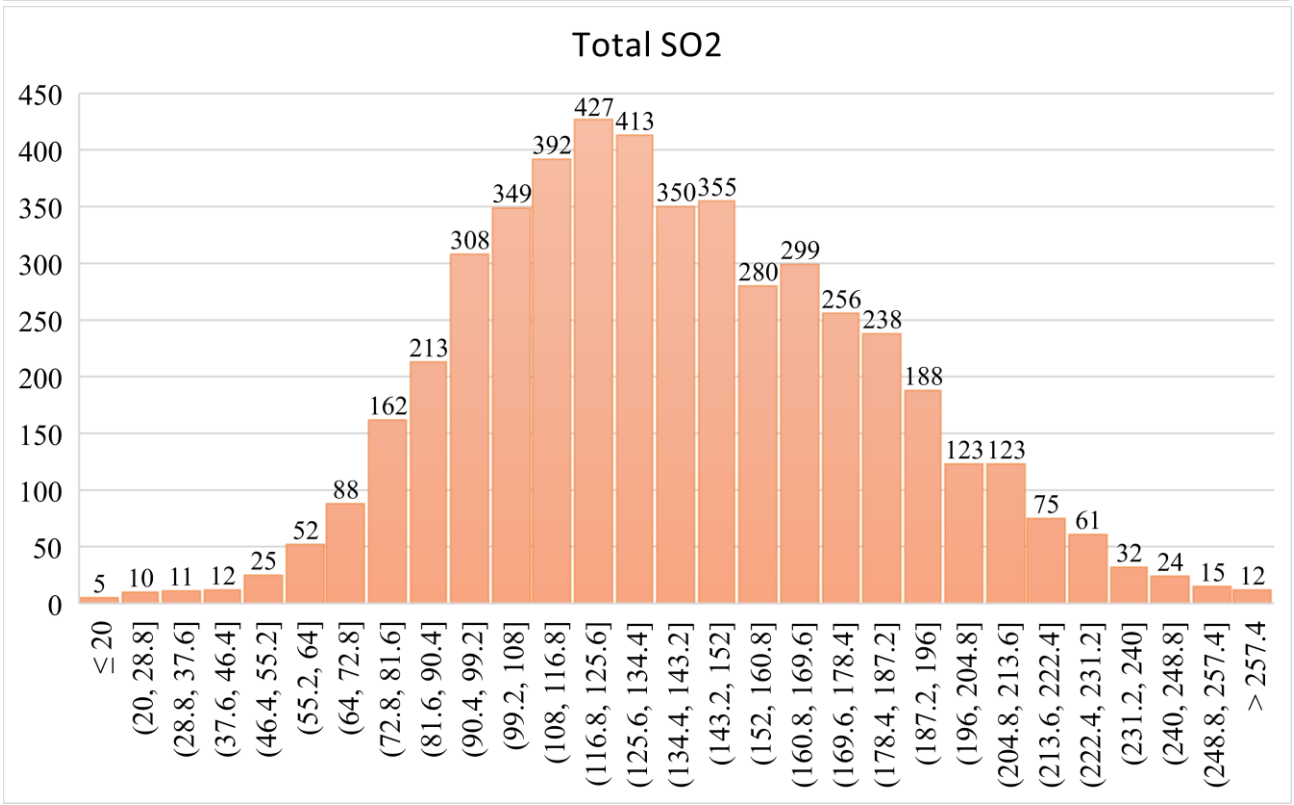


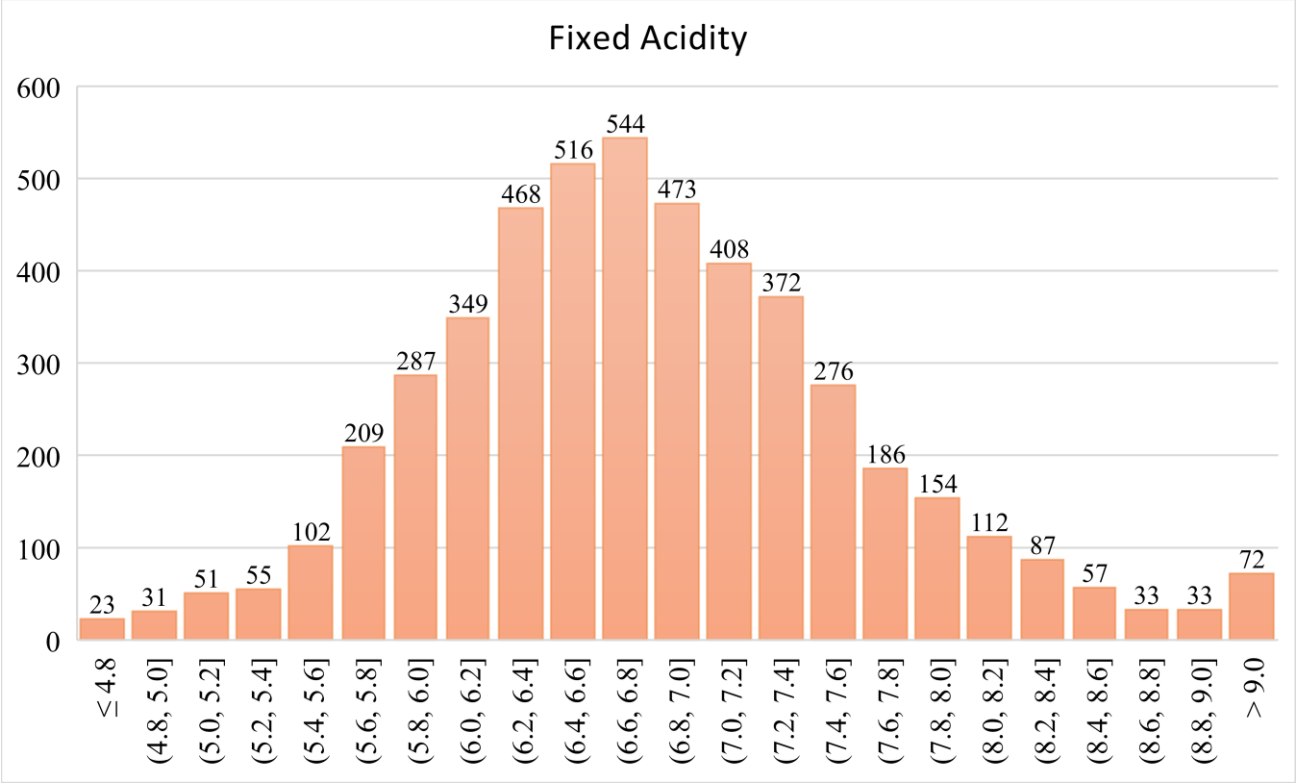


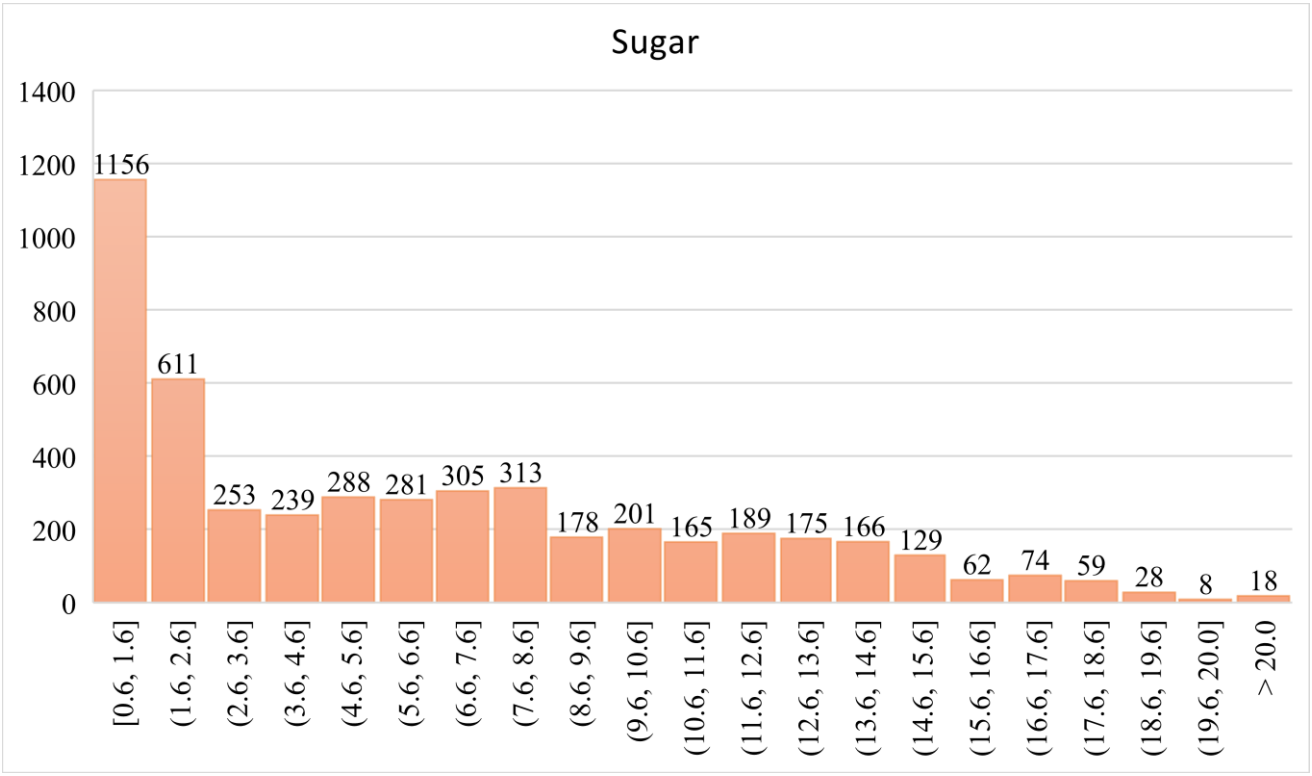

Chlorides
800
700
600
500
400
300
200
100
0
56
92
227
405
617
666
673
696
522
378
203
82
51
31
24
11
14
12
7
16
5
110
≤ 0.020
(0.020, 0.024]
(0.024, 0.028]
(0.028, 0.032]
(0.032, 0.036]
(0.036, 0.040]
(0.040, 0.044]
(0.044, 0.048]
(0.048, 0.052]
(0.052, 0.056]
(0.056, 0.060]
(0.060, 0.064]
(0.064, 0.068]
(0.068, 0.072]
(0.072, 0.076]
(0.076, 0.080]
(0.080, 0.084]
(0.084, 0.088]
(0.088, 0.092]
(0.092, 0.096]
(0.096, 0.100]
> 0.100

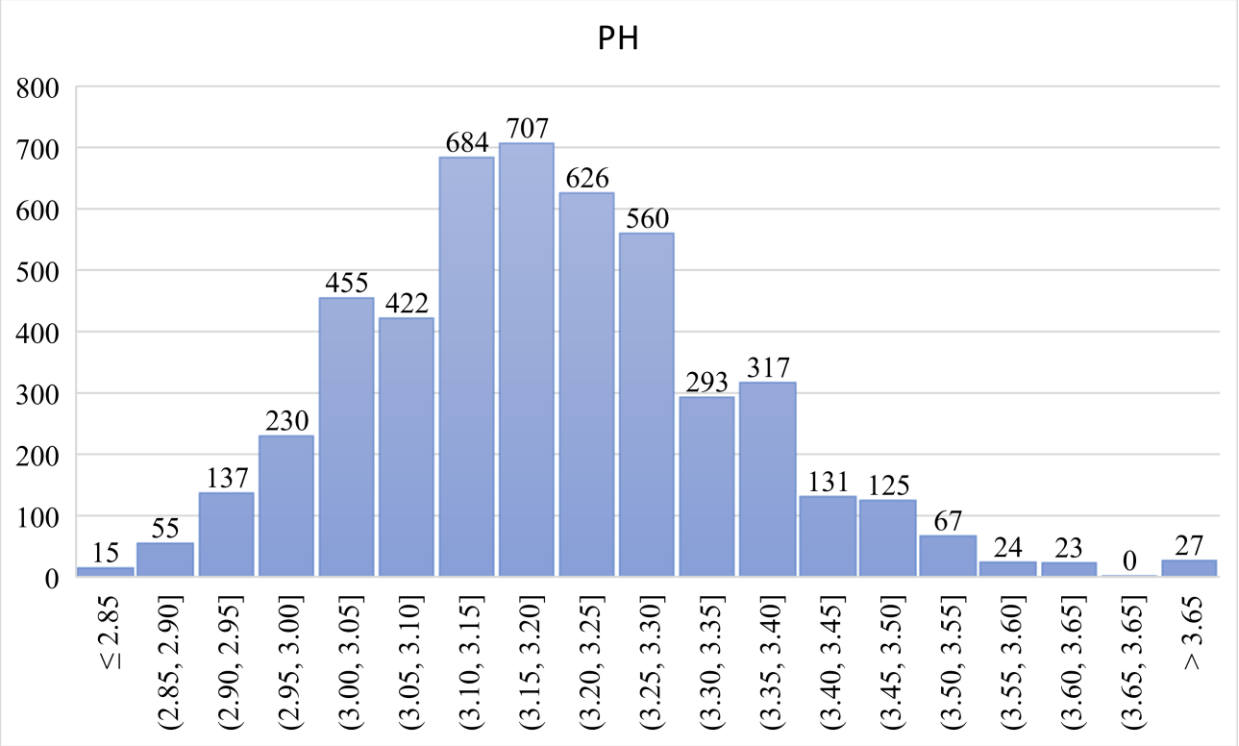

Density
700
600
500
400
300
200
100
0
14
73
315
472
613
605
574
474
538
353
373
284
145
50
15
[0.9871, 0.9881]
(0.9881, 0.9891]
(0.9891, 0.9901]
(0.9901, 0.9911]
(0.9911, 0.9921]
(0.9921, 0.9931]
(0.9931, 0.9941]
(0.9941, 0.9951]
(0.9951, 0.9961]
(0.9961, 0.9971]
(0.9971, 0.9981]
(0.9981, 0.9991]
(0.9991, 1.0001]
(1.0001, 1.0011]
> 1.0011


Volatile Acidity
700
600
500
400
300
200
100
0
12
56
104
238
325
388
425
477
486
649
353
322
237
172
130
118
75
77
48
50
20
18
26
11
15
66
[0.08, 0.10]
(0.10, 0.12]
(0.12, 0.14]
(0.14, 0.16]
(0.16, 0.19]
(0.19, 0.21]
(0.21, 0.23]
(0.23, 0.25]
(0.25, 0.27]
(0.27, 0.29]
(0.29, 0.31]
(0.31, 0.33]
(0.33, 0.35]
(0.35, 0.37]
(0.37, 0.40]
(0.40, 0.42]
(0.42, 0.44]
(0.44, 0.46]
(0.46, 0.48]
(0.48, 0.50]
(0.50, 0.52]
(0.52, 0.54]
(0.54, 0.56]
(0.56, 0.58]
(0.58, 0.60]
> 0.60

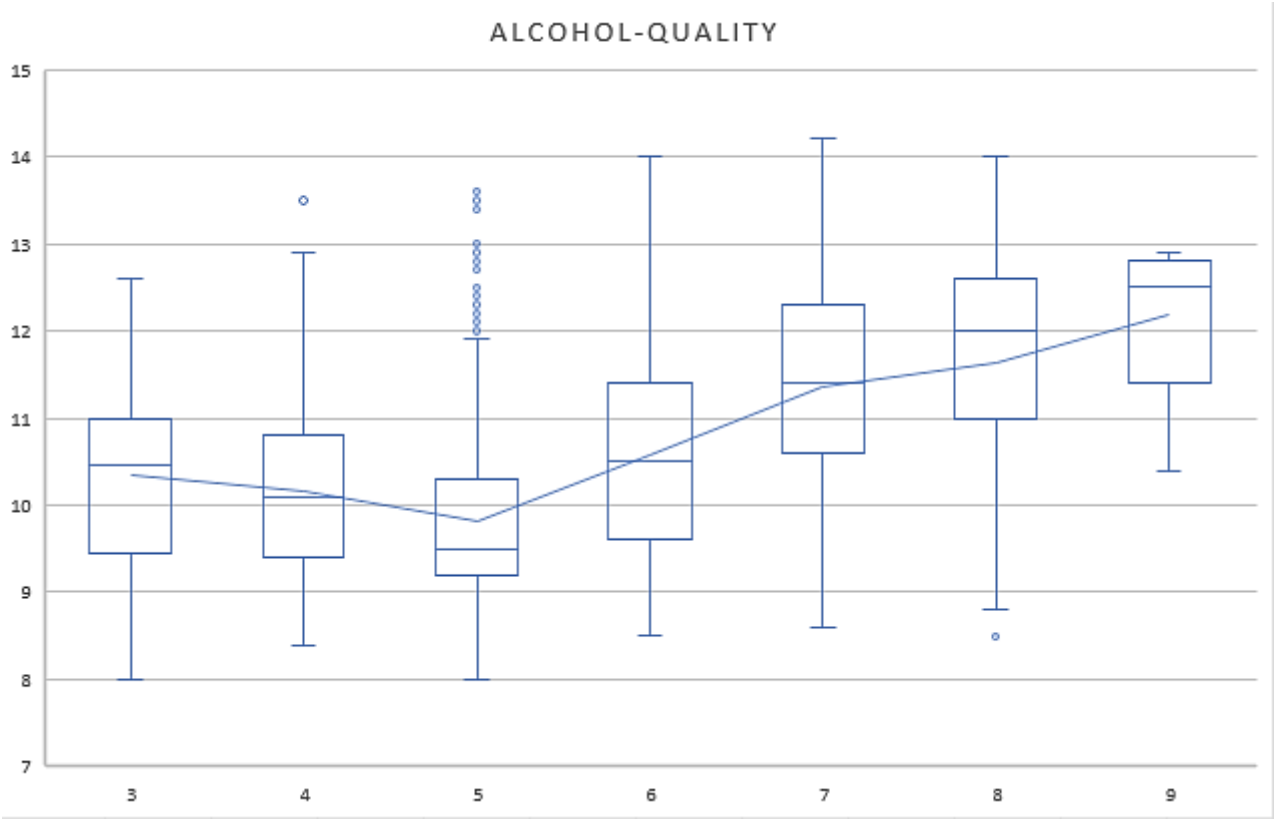

Total SO2
450
400
350
300
250
200
150
100
50
0
5
10
11
12
25
52
88
162
213
308
349
392
427
413
350
355
280
299
256
238
188
123
123
75
61
32
24
15
12
≤ 20
(20, 28.8]
(28.8, 37.6]
(37.6, 46.4]
(46.4, 55.2]
(55.2, 64]
(64, 72.8]
(72.8, 81.6]
(81.6, 90.4]
(90.4, 99.2]
(99.2, 108]
(108, 116.8]
(116.8, 125.6]
(125.6, 134.4]
(134.4, 143.2]
(143.2, 152]
(152, 160.8]
(160.8, 169.6]
(169.6, 178.4]
(178.4, 187.2]
(187.2, 196]
(196, 204.8]
(204.8, 213.6]
(213.6, 222.4]
(222.4, 231.2]
(231.2, 240]
(240, 248.8]
(248.8, 257.4]
> 257.4

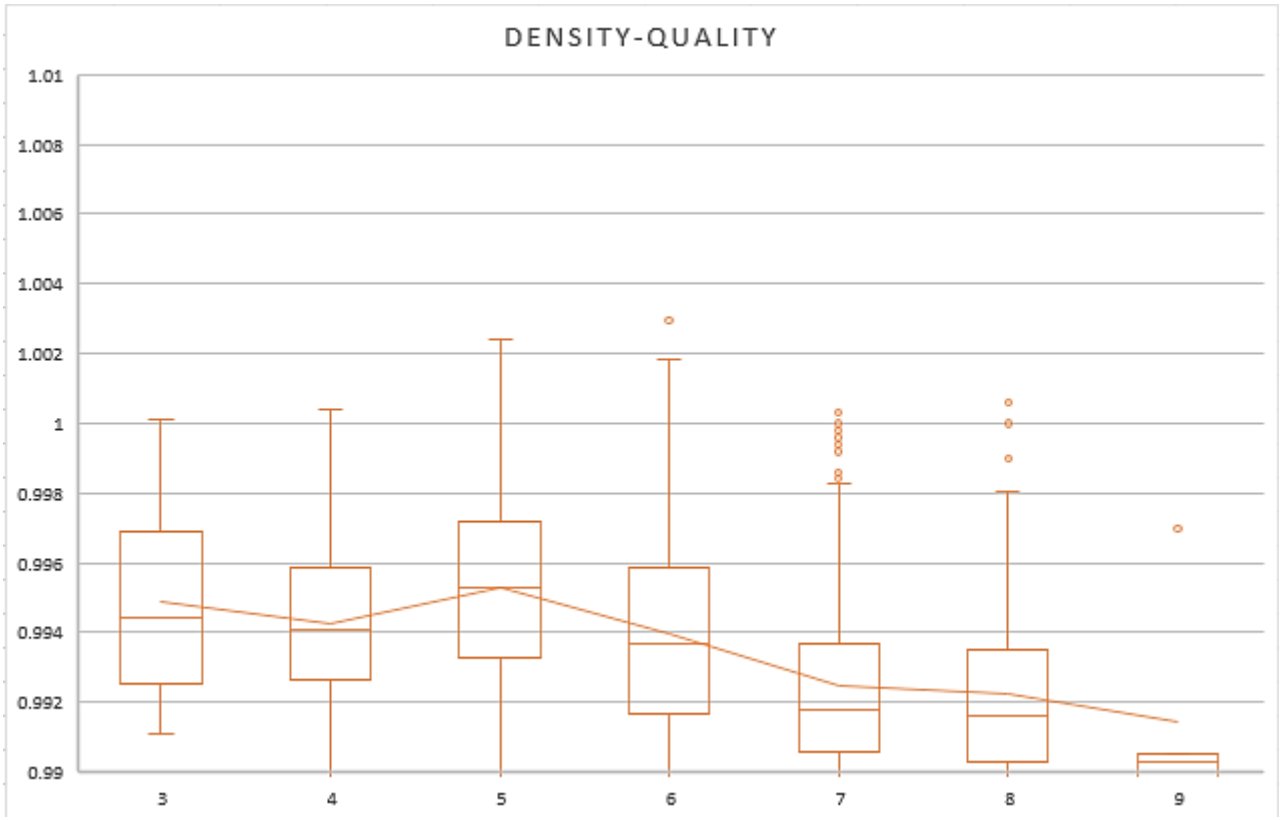

Fixed Acidity
600
500
400
300
200
100
0
23
31
51
55
102
209
287
349
468
516
544
473
408
372
276
186
154
112
87
57
33
33
72
<= 4.8
(4.8, 5.0]
(5.0, 5.2]
(5.2, 5.4]
(5.4, 5.6]
(5.6, 5.8]
(5.8, 6.0]
(6.0, 6.2]
(6.2, 6.4]
(6.4, 6.6]
(6.6, 6.8]
(6.8, 7.0]
(7.0, 7.2]
(7.2, 7.4]
(7.4, 7.6]
(7.6, 7.8]
(7.8, 8.0]
(8.0, 8.2]
(8.2, 8.4]
(8.4, 8.6]
(8.6, 8.8]
(8.8, 9.0]
> 9.0

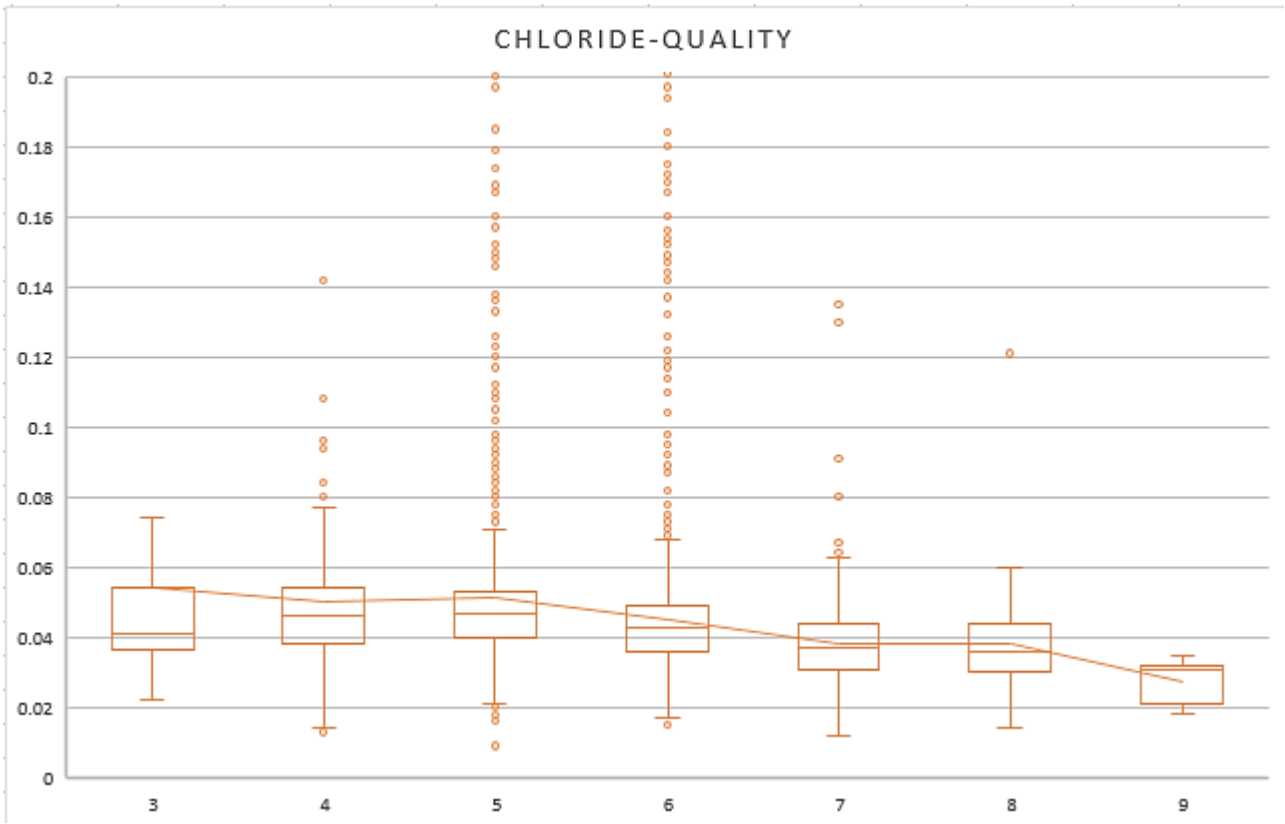

Sugar
1400
1200
1000
800
600
400
200
0
1156
611
253
239
288
281
305
313
178
201
165
189
175
166
129
62
74
59
28
8
18
[0.6, 1.6]
(1.6, 2.6]
(2.6, 3.6]
(3.6, 4.6]
(4.6, 5.6]
(5.6, 6.6]
(6.6, 7.6]
(7.6, 8.6]
(8.6, 9.6]
(9.6, 10.6]
(10.6, 11.6]
(11.6, 12.6]
(12.6, 13.6]
(13.6, 14.6]
(14.6, 15.6]
(15.6, 16.6]
(16.6, 17.6]
(17.6, 18.6]
(18.6, 19.6]
(19.6, 20.0]
> 20.0

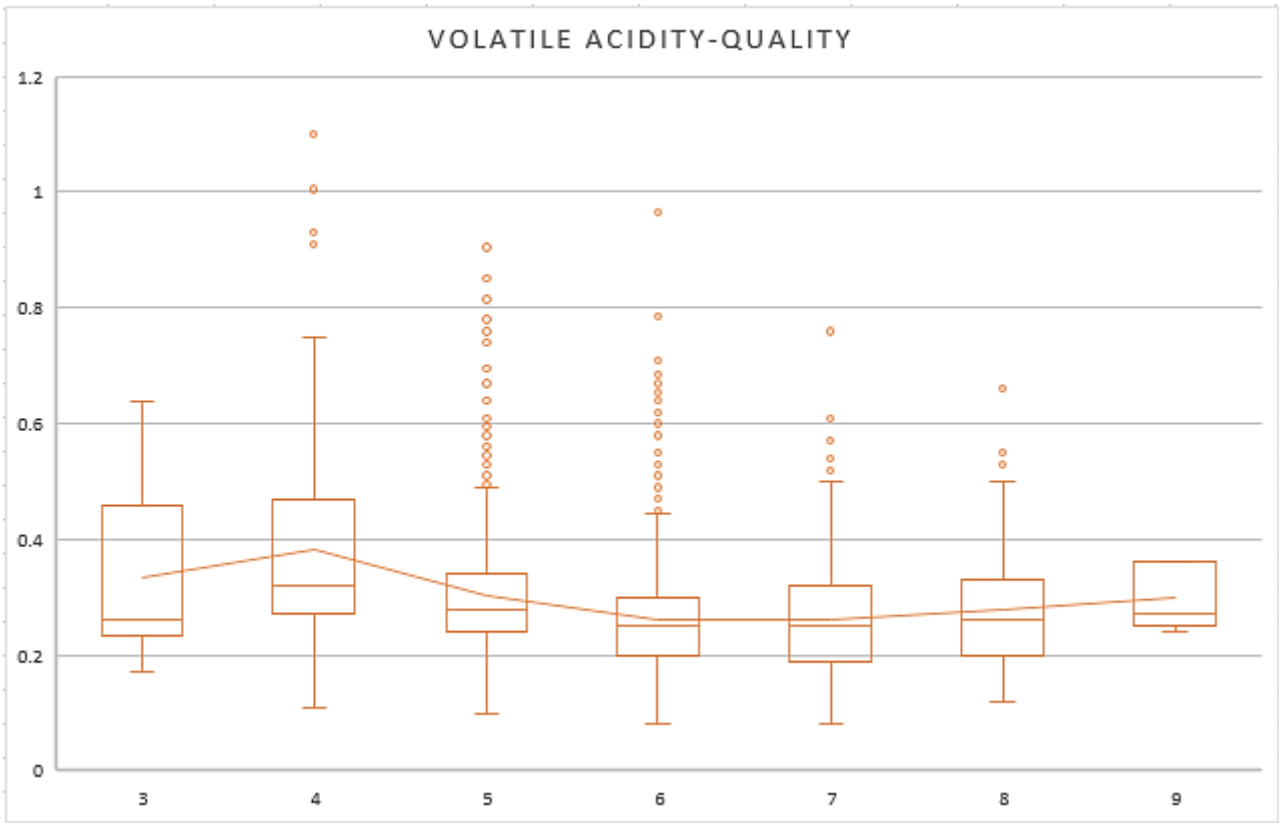


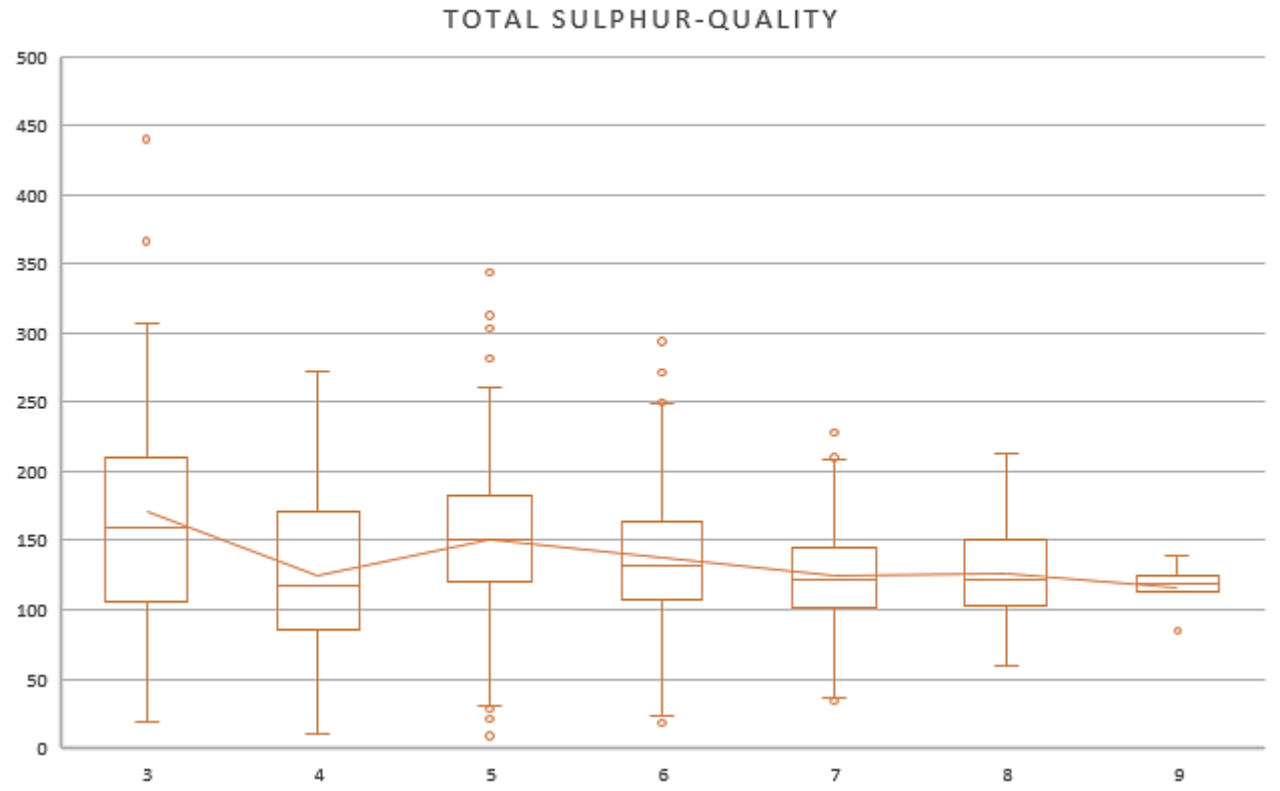
- **نمودار های جعبه ای:** در این نمودارها پراکندگی صفت های مختلف در کیفیت های مختلف نشان داده شده است. ارتفاع جعبه میزان وابستگی کیفیت به یک پارامتر را به ما نشان می دهد. نمودارهای آبی نشان دهنده نسبت مستقیم و نمودارهای نارنجی نشان دهنده نسبت معکوسِ بین آن صفت و کیفیت است.

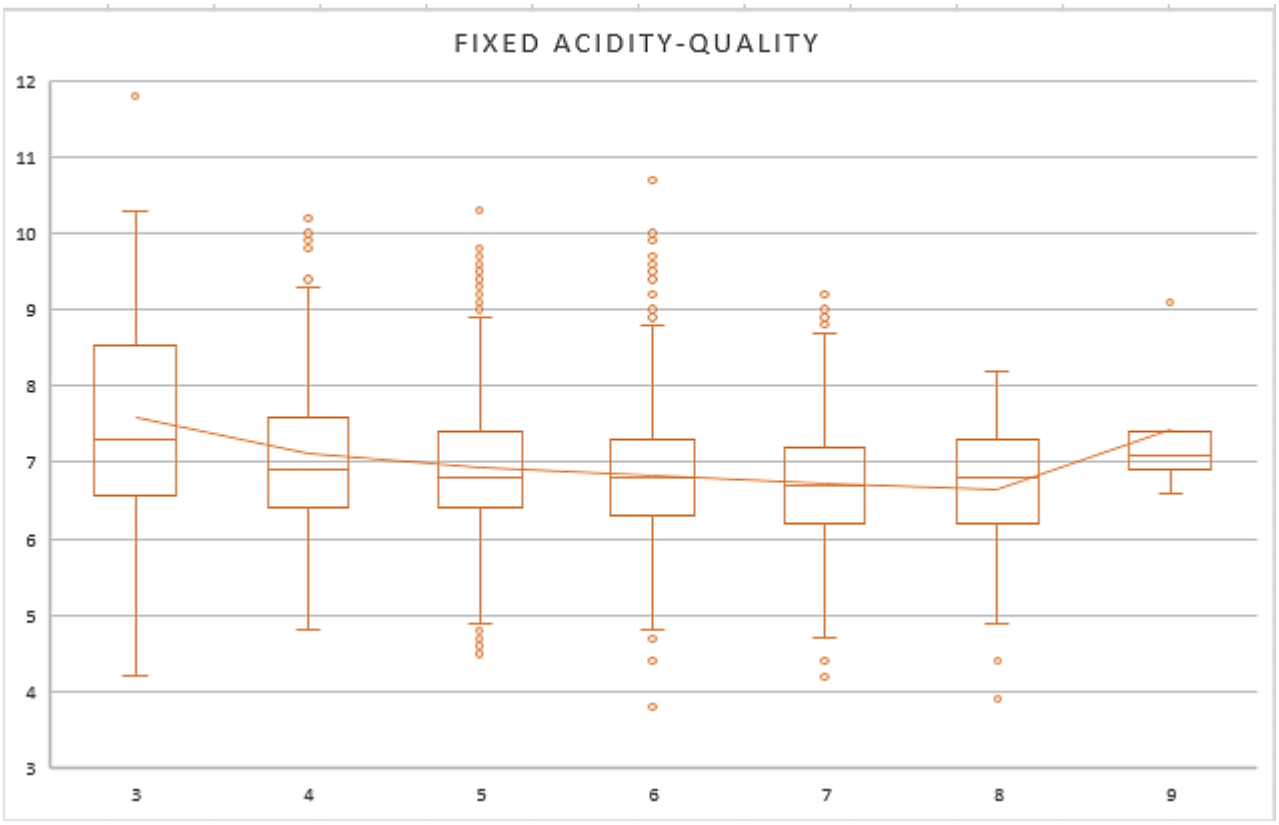


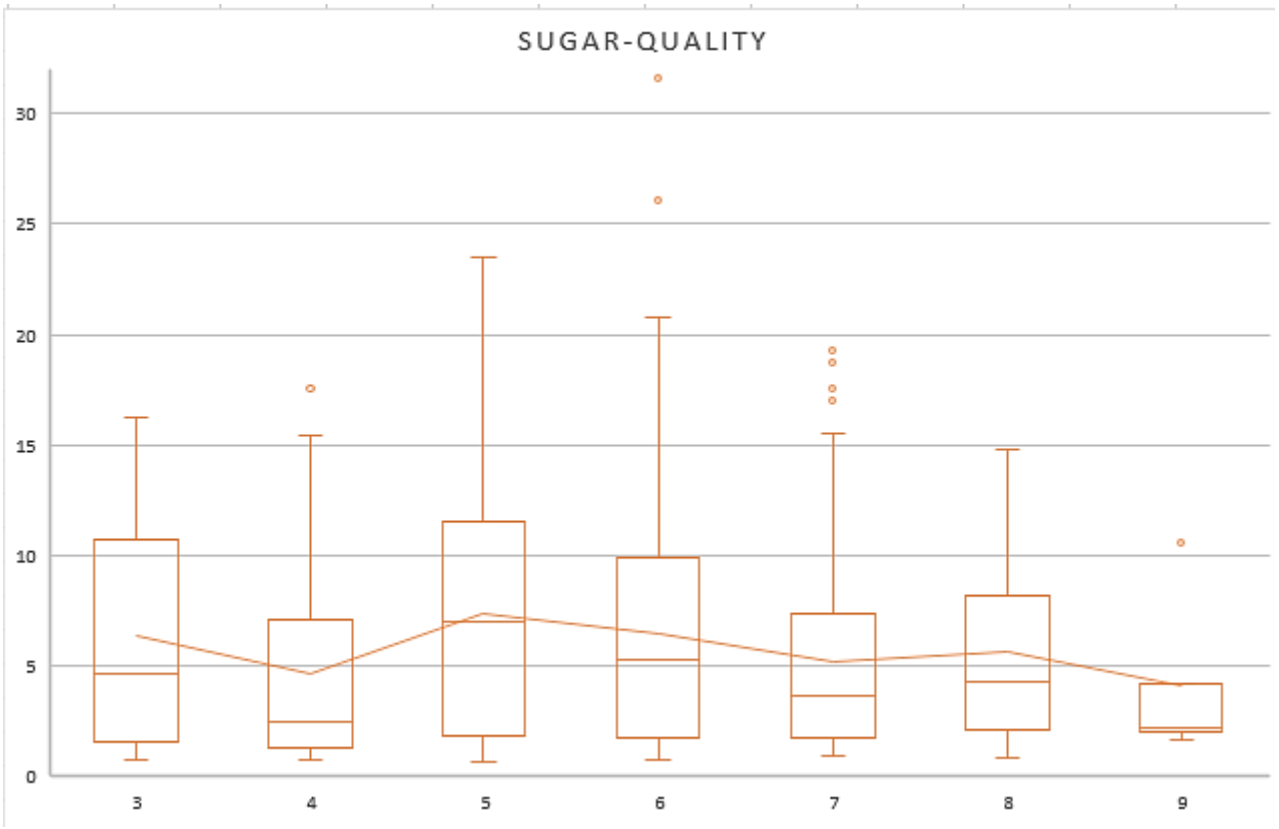

DENSITY-QUALITY
1.01
1.008
1.006
1.004
1.002
1
0.998
0.996
0.994
0.992
0.99
3
4
5
6
7
8
9

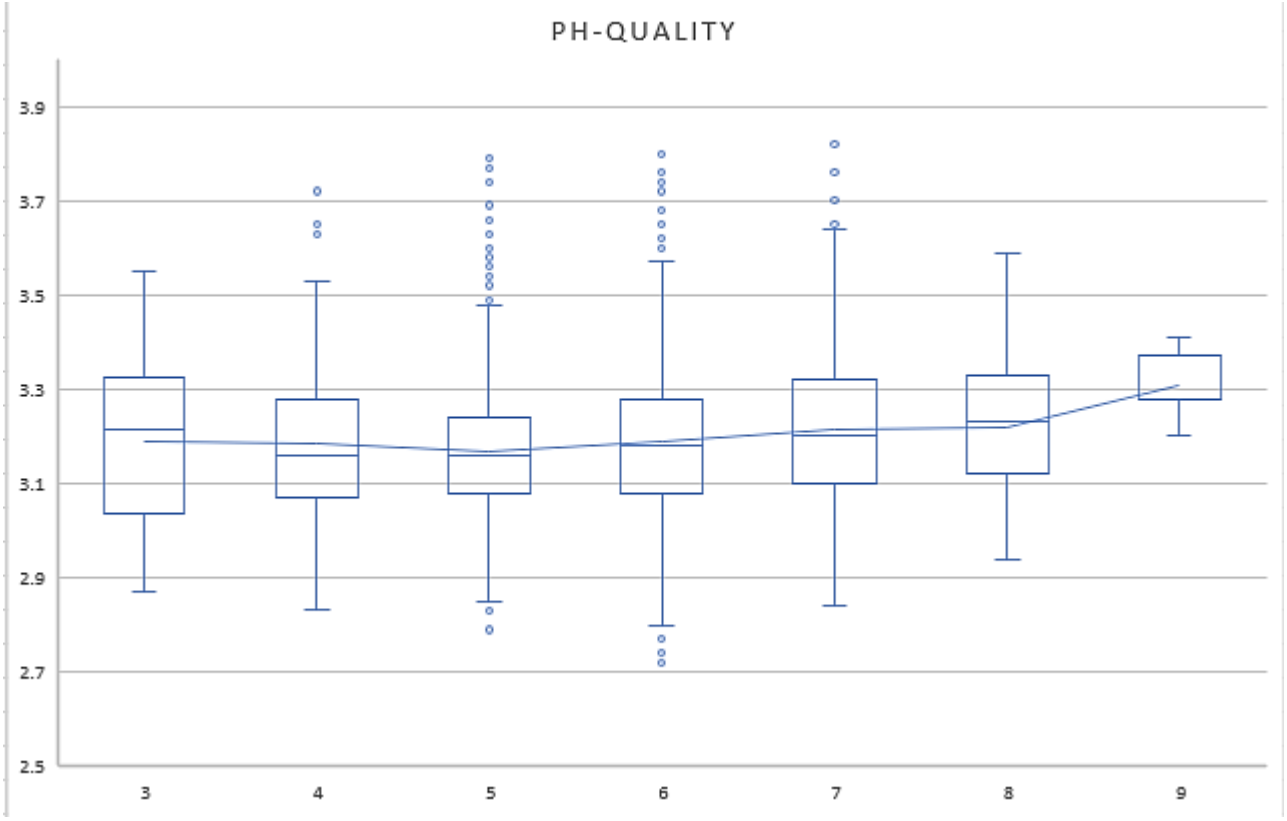

CHLORIDE-QUALITY
0.2
0.18
0.16
0.14
0.12
0.1
0.08
0.06
0.04
0.02
0
3
4
5
6
7
8
9


VOLATILE ACIDITY-QUALITY
1.2
1
0.8
0.6
0.4
0.2
0
3
4
5
6
7
8
9


TOTAL SULPHUR-QUALITY
500
450
400
350
300
250
200
150
100
50
0
3
4
5
6
7
8
9


FIXED ACIDITY-QUALITY
12
11
10
9
8
7
6
5
4
3
3
4
5
6
7
8
9


SUGAR-QUALITY
30
25
20
15
10
5
0
3
4
5
6
7
8
9



نتایج:

- در شراب های با کیفیت متوسط رو به بالا، هر چقدر کیفیت بالاتر می رود، متوسط میزان الکل نیز افزایش پیدا میکند. همچنین در با کیفیت ترین شراب ها ضمن پراکندگی کمتر میزان الکل در بازه ۱۰,۴ تا ۱۲,۸، متوسط میزان الکل به ۱۲,۵ می رسد.
- در شراب های با کیفیت متوسط رو به بالا، هر چقدر کیفیت بالاتر می رود، پراکندگی میزان قند و میانگین آن کاهش پیدا می کند به طوری که در با کیفیت ترین شراب ها، قند کمتر از ۴,۲ گرم بر لیتر است.
- بین قند و چگالی همبستگی مستقیم وجود دارد به طوری که با کاهش قند، چگالی نیز کاهش پیدا می کند.
- در مقدار متوسط اسیدهای فرار در شراب های با کیفیت متوسط و شراب های با کیفیت اختلاف معناداری دیده نمیشود.
- معمولا با کاهش میزان الکل، چگالی افزایش می یابد.
- در شراب های با کیفیت متوسط رو به بالا، ضمن افزایش کیفیت، میزان نمک کاهش پیدا می کند.
- معمولا شراب های با کیفیت متوسط کمترین میزان الکل را دارند.